AI-VIETNAM

KHÓA HỌC AIO2026

BÁO CÁO TIẾN ĐỘ TUẦN 1

Submission I – Module 05

DocuCheck AI

Hệ thống xử lý và kiểm tra tài liệu

Hiểu dữ liệu, xử lý tái lập và OCR baseline

Tên nhóm	Winner Winner Chicken Dinner
Thành viên 1	Nguyễn Văn Minh
Thành viên 2	Nguyễn Thành Trung

Ngày lập báo cáo: 28 tháng 10 năm 2026

github.com/AIVIETNAM-AIO-Heart208/DocuCheck-AI

Tóm tắt

DocuCheck AI nghiên cứu xử lý biên lai tiếng Việt dựa trên bằng chứng ảnh. Tuần 1 tập trung hiểu dữ liệu, chuẩn hóa quy trình tái lập và thiết lập OCR baseline. Bản MC-OCR cục bộ gồm 1.546 bản ghi hóa đơn, 6.585 vùng KIE và 40.868 vùng transcript toàn trang; 6.585 cặp crop/transcript thuộc nguồn nhận dạng riêng. Kiểm tra EDA cho thấy độ phân giải, độ sáng và độ nét biến thiên; worksheet của mẫu 40 ảnh ghi 6 đúng, 32 sai và 2 bất định. Mẫu ưu tiên rủi ro nên không đại diện tỷ lệ lỗi toàn tập. Pipeline schema 1.1 giữ nguyên annotation nguồn, chia nhóm SHA-256 với seed 42 và cách ly 20 bản ghi train trùng validation chính thức. Kiểm định cấu trúc đạt trên 8.131 bản ghi, đồng thời ghi nhận 115 hóa đơn có lỗi geometry nguồn. Artifact OCR hiện có ghi Tesseract CPU hoàn thành 231 ảnh dev và 26.859 word boxes. Tái tính từ prediction cho micro CER 1,8725 và WER 2,1448, khác số lịch sử trong tài liệu. Các giá trị chịu ảnh hưởng của transcript và ghép vùng, chưa phải benchmark nhận dạng độc lập. Báo cáo đối chiếu artifact, mã nguồn và 106 kiểm thử đạt; chưa đánh giá mô hình KIE, phân xử gần trùng hoặc triển khai chức năng sản phẩm.

Quy ước minh chứng. Đã kiểm chứng nghĩa là đã đọc artifact và thực hiện phép đối chiếu được mô tả trong lần lập báo cáo. **Lịch sử** là kết quả chỉ được ghi trong tài liệu hoặc log có sẵn. **Chưa xác minh** là chưa đủ bằng chứng độc lập. Mã [E01]–[E15] dẫn đến danh mục ở phụ lục và `EVIDENCE_INDEX.md`.

Phạm vi và mốc kiểm tra

Báo cáo đối chiếu mã nguồn tại commit `4ee2776` với dữ liệu và artifact cục bộ ngày 28/10/2026 (Asia/Saigon). EDA và evaluation được tái tính; inference OCR, preparation và notebook không được chạy lại trong lần lập báo cáo. Hash nguồn và trạng thái notebook workspace được ghi trong phụ lục minh chứng. [E01][E12][E14]

Mục lục

Tóm tắt i

I Tổng quan dự án 1
1.1 Bối cảnh và định hướng . . . 1
1.2 Phạm vi thực hiện và tiêu chí đánh giá . . . 1
1.3 Ranh giới với mục tiêu dài hạn . . . 1

II Goal 1: Hiểu dataset và phân tích khám phá 1
2.1 Dataset MC-OCR và bản export cục bộ . . . 1
2.2 Phân bố annotation và độ bao phủ . . . 2
2.3 EDA kích thước và các heuristic ảnh . . . 3
2.4 Phương pháp audit chất lượng annotation . . . 4
2.5 Trùng chính xác và ứng viên gần trùng . . . 4
2.6 Đánh giá Goal 1 . . . 5

III Goal 2: Xử lý dữ liệu tái lập 5
3.1 Luồng xử lý và đầu ra . . . 5
3.2 Schema 1.1 và provenance . . . 5
3.3 Trạng thái thiếu và kiểm định hình học . . . 6
3.4 Chia tập xác định và cách ly trùng . . . 6
3.5 Ba chính sách xử lý dữ liệu không hợp lệ . . . 6
3.6 Tính xác định và kiểm định bundle . . . 7
3.7 Staging, thay thế và giới hạn rollback . . . 7
3.8 Đánh giá Goal 2 . . . 7

IV Goal 3: OCR baseline và phân tích lỗi 8
4.1 Mục tiêu baseline và cấu hình thực tế . . . 8
4.2 Inference, word boxes và theo dõi lỗi . . . 8
4.3 Ghép prediction với ground truth . . . 8
4.4 CER, WER và chuẩn hóa tiếng Việt . . . 9
4.5 Kết quả hiện có và số liệu lịch sử . . . 9
4.6 Phân bố lỗi và các nguồn sai khác . . . 11
4.7 Đánh giá Goal 3 . . . 11

V Tổng hợp kiểm thử và kiểm chứng 12
5.1 Kiểm chứng thực hiện trong lần lập báo cáo . . . 12
5.2 Kết quả lịch sử và trạng thái CI . . . 12

VI Thảo luận, kết luận và hướng tiếp theo 12
6.1 Quan hệ giữa ba mục tiêu . . . 12
6.2 Những giới hạn còn lại . . . 13
6.3 Kết luận . . . 13
6.4 Hướng tiếp theo theo bàn giao Week 2 . . . 13

Tài liệu tham khảo 14

PHỤ LỤC – DANH MỤC MINH CHỨNG 15

I. Tổng quan dự án

1.1 Bối cảnh và định hướng

DocuCheck AI hướng tới chuyển ảnh biên lai bán lẻ tiếng Việt thành bản ghi có cấu trúc, gắn mỗi giá trị với vùng ảnh nguồn và hỗ trợ người dùng rà soát. Bốn trường ban đầu là tên nơi bán, địa chỉ, ngày/giờ giao dịch và tổng tiền. OCR cung cấp nội dung cùng vị trí; Key Information Extraction (KIE) gán nội dung vào trường; bước kiểm tra cần quy tắc và đủ dữ kiện để đối chiếu. Theo product brief, cảnh báo sai lệch chỉ là yêu cầu xem lại, không phải kết luận gian lận. [E02]

Ảnh chụp bằng điện thoại thường có nền phức tạp, ánh sáng không đều, giấy nhăn, chữ phai hoặc chuyển động. Đây cũng là những khó khăn được mô tả trong tác vụ MC-OCR chính thức [1]. Với tiếng Việt, dấu thanh và dấu nguyên âm làm cho sai khác ký tự nhỏ ảnh hưởng đến khả năng đọc đúng; bố cục nhiều dòng và cách ghi tiền/ngày làm tăng yêu cầu giữ ngữ cảnh. Tuần 1 khảo sát những yếu tố này ở mức dữ liệu và baseline, chưa chứng minh một giải pháp sản phẩm hoàn chỉnh.

1.2 Phạm vi thực hiện và tiêu chí đánh giá

Ba mục tiêu được đánh giá theo deliverable thực tế: có thống kê và audit truy vết được; có quy trình chuẩn hóa, chia tập và kiểm định tái lập; có một baseline OCR chạy được và phân tích giới hạn phép đo. Không đặt thêm ngưỡng accuracy ngoài yêu cầu gốc. Bảng 1 tóm tắt trạng thái dựa trên bằng chứng cục bộ.

Bảng 1: Phạm vi hoàn thành của ba mục tiêu tuần 1.

Mục tiêu	Nội dung	Deliverable chính	Đánh giá
Goal 1	Hiểu dữ liệu và EDA	Thống kê, audit annotation 40 ảnh, phân tích trùng/gần trùng	Hoàn thành khảo sát; còn rủi ro nguồn
Goal 2	Xử lý dữ liệu tái lập	Manifest schema 1.1, split, validation, kiểm chứng artifact	Hoàn thành pipeline; bundle gốc còn metadata cũ
Goal 3	OCR baseline và phân tích lỗi	Tesseract, predictions, CER/WER, chẩn đoán alignment	Hoàn thành baseline đầu tiên; phép đo có giới hạn

Nguồn: Đối chiếu [E03]–[E13]; hoàn thành không đồng nghĩa annotation sạch hoặc OCR đạt chất lượng triển khai.

1.3 Ranh giới với mục tiêu dài hạn

Tuần 1 chưa huấn luyện mô hình KIE, chưa có accuracy trích xuất trường hoặc field-level F1. Chức năng kiểm tra nghiệp vụ, API, giao diện và triển khai ứng dụng chưa được nghiệm thu. Crop nhận dạng chữ không được sử dụng như nhãn trường hóa đơn khi chưa xác minh quan hệ nguồn. Những phân biệt này giúp đọc đúng cả thành công của pipeline lẫn giới hạn của kết quả OCR. [E02][E09]

II. Goal 1: Hiểu dataset và phân tích khám phá

2.1 Dataset MC-OCR và bản export cục bộ

MC-OCR nghiên cứu ảnh hóa đơn chụp bằng thiết bị di động, gồm đánh giá chất lượng ảnh và trích xuất thông tin. Tài liệu chính thức cho phép một ảnh không có đủ trường mục tiêu hoặc có dòng không đọc

được [1, 2]. Bản cục bộ được dự án hướng dẫn lấy từ Kaggle; lần lập báo cáo kiểm tra dữ liệu đã tồn tại, không xác nhận lại toàn bộ lịch sử tải hoặc điều khoản phân phối. Tổng số của cuộc thi không được dùng thay cho inventory thực tế. [E02][E03]

Ba nguồn annotation cần được phân biệt. **KIE** cung cấp nhãn trường, transcript và polygon của trường mục tiêu. **Transcript toàn trang** nằm trong sidecar được ghép với ảnh train theo tên tệp tường minh. **Recognition crop/transcript** là tác vụ nhận dạng độc lập với train/val riêng; không có quan hệ parent receipt hoặc vùng KIE đã được kiểm chứng. Hai nguồn cùng có 6.585 phần tử không chứng minh chúng tương ứng một-một.

Bảng 2: Quy mô bản export; đơn vị đếm và mẫu số được tách riêng.

Thành phần	Số lượng	Định nghĩa / giới hạn
Bản ghi hóa đơn	1.546	1.155 train và 391 inventory validation
Nội dung hóa đơn duy nhất	1.491	Nhóm theo SHA-256 toàn bộ tệp ảnh
Ảnh nguồn KIE train	1.155	1.122 nội dung khác nhau theo SHA-256
Vùng KIE của train	6.585	Polygon trường, không phải số ảnh
Ảnh train có sidecar OCR	1.151	Trên 1.155 ảnh; thiếu 4 sidecar
Vùng transcript toàn trang	40.868	Bao gồm geometry không hợp lệ
Cặp recognition crop/transcript	6.585	5.285 train; 1.300 val riêng
Tổng bản ghi ảnh kiểm định	8.131	1.546 hóa đơn + 6.585 crop

Nguồn: Tái đếm manifest và nguồn, giải mã ảnh và kiểm SHA-256: [E03][E12].

Inventory validation chính thức gồm 391 ảnh nhưng CSV cục bộ không có cột nhãn/polygon KIE. Việc có cột transcript mẫu không tạo ra GT KIE hoặc transcript toàn trang phù hợp cho benchmark hiện tại. Do đó pipeline giữ tập này làm inventory, không suy nhãn và không dùng kết quả tuning từ đây. [E03][E06]

2.2 Phân bố annotation và độ bao phủ

Trên 1.155 bản ghi train, số vùng KIE mỗi ảnh có min 0, Q1 5, trung vị 5, Q3 7, max 29 và trung bình 5,7013. Có hai mảng annotation rỗng; 947 ảnh có đủ bốn loại trường được ánh xạ. Một ảnh có nhiều vùng cho cùng trường nên số vùng và số ảnh có nhãn là hai đại lượng khác nhau. Không có annotation cho một trường chưa đủ để kết luận trường thực sự không xuất hiện trên ảnh. [E03][E12]

Bảng 3: Nhãn nguồn và độ bao phủ trên 1.155 bản ghi train.

Nhãn nguồn	Trường chuẩn	Vùng	Ảnh có nhãn	Không gán
`SELLER`	`seller_name`	1.171	1.071	84
`ADDRESS`	`seller_address`	1.952	1.077	78
`TIMESTAMP`	`transaction_datetime`	1.347	1.088	67
`TOTAL_COST`	`total_amount`	2.114	1.081	74
`TOTAL_TOTAL_COST`	Chưa ánh xạ	1	–	–

Nguồn: `loader.FIELD_MAPPING`, manifest và `verified_summary.json`; [E03][E12]. Mỗi trường còn 391 ảnh official inventory không có GT KIE, nằm ngoài mẫu số 1.155.

Bảng 3 cho thấy số vùng tổng tiền và địa chỉ lớn hơn số vùng nơi bán. Đây là phân bố annotation, chưa phản ánh độ khó mô hình hoặc tỷ lệ nhãn đúng. Nhãn bất thường được giữ nguyên để truy tìm và rà soát nguồn.

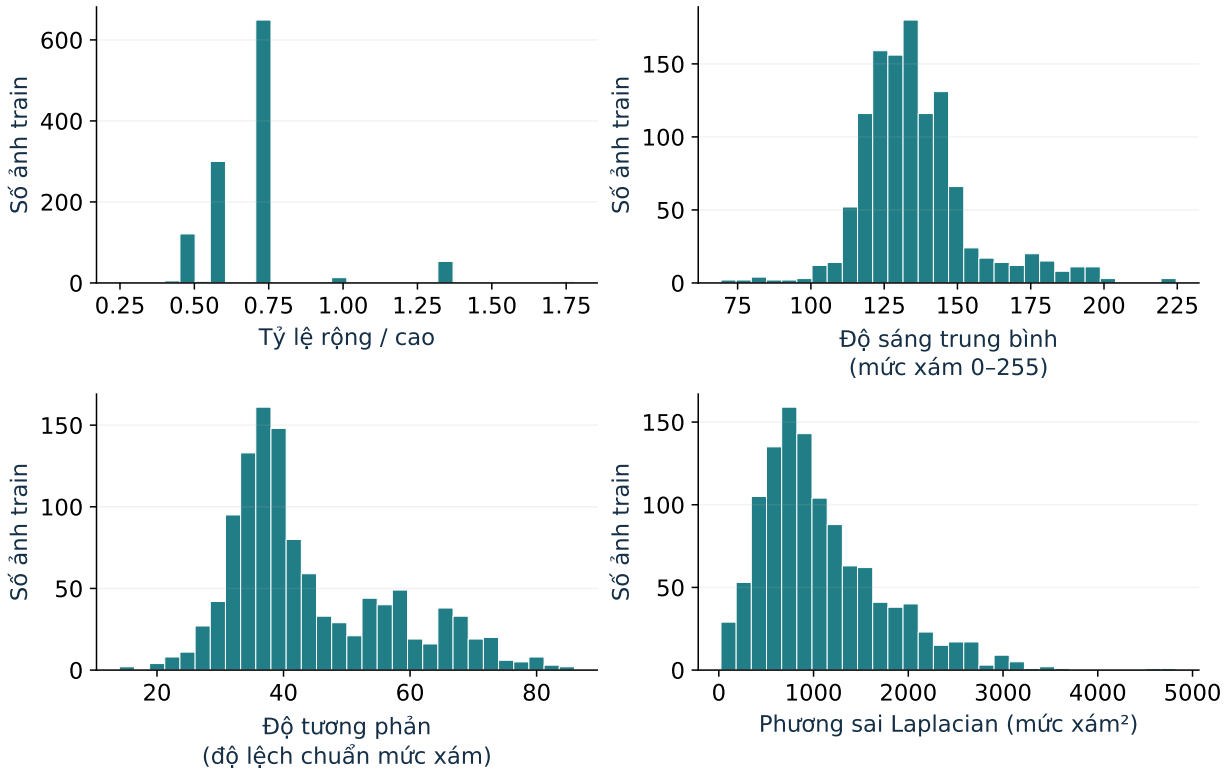
2.3 EDA kích thước và các heuristic ảnh

Bảng 4: Thống kê tái tính trên toàn bộ 1.155 ảnh train.

Đại lượng	Nhỏ nhất	Trung vị	Lớn nhất
Rộng (pixel)	352	768	1.024
Cao (pixel)	480	1.024	2.860
Tỷ lệ rộng/cao	0,2476	0,7500	1,7778
Độ sáng trung bình (mức xám)	69,3267	133,0371	224,6197
Tương phản (độ lệch chuẩn mức xám)	14,0370	39,5171	85,9794
Phương sai Laplacian (mức xám^2)	22,9347	918,3987	4.827,2302

Nguồn: `eda.collect_image_features()` đọc ảnh gốc, OpenCV ảnh xám; [E04][E12].

Các thống kê kích thước là từng phân bố độc lập: không suy rằng mọi ảnh đều có kích thước trung vị 768×1.024. Có 56 ảnh ngang và 1.099 ảnh dọc/vuông. Phương sai Laplacian phản ánh thay đổi cường độ cục bộ; độ nét, nhiễu và chất liệu nền đều có thể ảnh hưởng, vì thế không dùng riêng đại lượng này để chứng nhận ảnh dễ đọc.



Hình 1: Phân bố tỷ lệ hình dạng, độ sáng, tương phản và phương sai Laplacian của 1.155 ảnh train, không lọc bỏ ngoại lệ. Hình được tạo mới từ dữ liệu thật bằng hàm EDA hiện có; nguồn [E04][E12].

Hình 1 cho thấy sự biến thiên của tín hiệu ảnh và đuôi phải rõ ở phương sai Laplacian. Những phân bố

này hỗ trợ chọn ca khó để kiểm tra, không thay thế đánh giá khả năng đọc của con người. Dự án chưa hiệu chuẩn các heuristic thành điểm chất lượng có ground truth hoặc chứng minh một ngưỡng ảnh tốt/xấu.

2.4 Phương pháp audit chất lượng annotation

`select_annotation_audit_sample()` chọn 40 ảnh nguồn train không hoàn lại với seed 42. Các tầng chồng lấp gồm cảnh báo geometry, nhãn chưa ánh xạ, mảng KIE rỗng, thiếu transcript, tứ phân vị độ nét và độ phủ/mật độ nhãn. Hàm ưu tiên tầng hiếm và chọn luân phiên sau trộn xác định; mẫu đã được tái tạo đúng 40 ID, thứ tự và lý do chọn. [E04][E05][E12]

Quy trình review gồm xem ảnh gốc và overlay, so nhãn/text/polygon với pixel, tìm trường hiện rõ chưa gán và ghi phần chưa chắc chắn. Worksheet đã lưu 40 dòng `reviewed`: 6 `correct`, 32 `incorrect`, 2 `uncertain`. Lần lập báo cáo kiểm tra CSV và tính nhất quán với mẫu, không review lại pixel. [E05]

Giới hạn suy luận. Đây là mẫu ưu tiên tìm lỗi; tỷ lệ 32/40 không ước lượng tỷ lệ lỗi toàn dataset. Audit ghi nhận rủi ro, chưa làm sạch annotation.

Bảng 5: Các cờ trong worksheet 40 ảnh; một ảnh có thể mang nhiều cờ.

Nhóm lỗi / cờ	Có	Bất định	Ý nghĩa
Sai nhãn KIE	8	2	Nội dung và ngữ nghĩa trường không khớp
Sai vị trí polygon	6	0	Vùng không bao đúng nội dung mục tiêu
Thiếu annotation trường	21	5	Cần nhìn rõ trường liên quan trước khi kết luận
Chữ không đọc được	3	0	Nhòe, phai hoặc che khuất
Có phần chưa chắc chắn	6	0	Khác với 2 kết luận tổng thể bất định

Nguồn: Tái đếm `annotation_review.csv`, đối chiếu `docs/ANNOTATION_AUDIT.md`; [E05][E12].

Sai transcript được ghi trong notes, chưa có cột cờ riêng; vì vậy không thể đếm taxonomy đầy đủ chỉ bằng các cột nhãn, geometry và thiếu trường. Tài liệu mô tả năm ca chỉ sai transcript và sự bất định với báo cáo Z/phiếu bếp. Báo cáo này không chép nội dung biên lai hoặc ảnh riêng tư. Tổng các cờ ở Bảng 5 không phải số ảnh lỗi độc nhất. Metadata `not_performed` trong audit summary là trạng thái lúc sinh mẫu; CSV mới phản ánh review hoàn tất.

Kiểm tra geometry toàn tập xác nhận 6 vùng KIE trên 6 ảnh có tự giao/chạm cạnh không kề, trong đó 4 có đỉnh lặp; transcript toàn trang có 425 vùng vượt biên trên 109 ảnh. Tổng 115 hóa đơn có vấn đề geometry. Sáu ca geometry nguồn này khác sáu ca polygon sai vị trí trong mẫu review: một kiểm tra tính hợp lệ hình học, một kiểm tra vùng có đúng nội dung trên ảnh hay không. [E03][E12]

2.5 Trùng chính xác và ứng viên gần trùng

Nguồn train có 31 nhóm SHA-256 trùng chứa 64 bản ghi. SHA-256 nhận biết tệp ảnh có byte giống nhau, không nhận biết mọi lần chụp cùng giao dịch. Hai mươi bản ghi train trùng official validation được cách ly trước chia nội bộ. Kiểm tra kết hợp receipt/crop không thấy nhóm SHA-256 đi qua các split đang hoạt động. [E07][E12]

Audit pHash riêng dùng ảnh xám 32×32, DCT 8×8, bỏ hệ số DC, tạo 63 bit AC và ngưỡng Hamming 6. Artifact ghi 1.526 ảnh băm được, 0 lỗi đọc; 36 cặp ứng viên gồm 10 train/dev, 22 train/official validation,

4 dev/official validation. Số cặp và phân nhóm đã đối chiếu với JSONL; lần này không tái chạy pHash. Các cặp chưa phân xử danh tính giao dịch. Bố cục chung có thể gây khớp giả, xoay/cắt mạnh có thể bị bỏ sót. [E08]

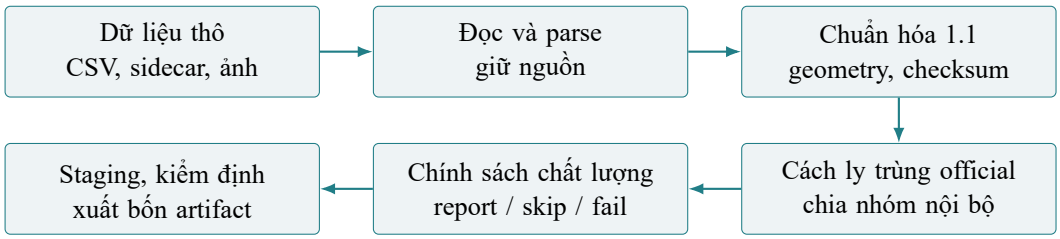
2.6 Đánh giá Goal 1

Đã có inventory, EDA, đối chiếu nguồn, audit 40 ảnh và danh sách rủi ro trùng. Bằng chứng đủ cho mục tiêu hiểu dữ liệu. Rủi ro còn lại là annotation sai/bất định, quy tắc cho loại chứng từ đặc biệt, 36 cặp chưa phân xử và quan hệ crop–receipt chưa xác minh. Chưa có cơ sở tuyên bố dữ liệu sạch hoặc benchmark hết leakage gần trùng.

III. Goal 2: Xử lý dữ liệu tái lập

3.1 Luồng xử lý và đầu ra

Các adapter trong `loader.py` đọc CSV KIE, sidecar transcript và manifest recognition riêng. `prepare_records()` kết hợp inventory, giải mã ảnh, tính checksum, chuẩn hóa annotation và gán split. CLI `prepare_dataset.py` ghi bốn artifact sau kiểm định. Notebook dùng lại các hàm này để khảo sát; không phải bước bắt buộc của pipeline. [E06]



Hình 2: Luồng chuẩn bị dữ liệu theo `prepare_records()` và CLI; recognition giữ split nguồn riêng. Trường hợp fail bị từ chối trước công bố bundle thành công. Nguồn [E06].

Hình 2 đặt chia tập trước lọc `skip`, đúng với mã hiện tại: những bản ghi giữ lại không được chia cân bằng lại. Bốn đầu ra gồm receipt manifest, recognition manifest, split summary và validation report. Dữ liệu raw không bị sửa; đầu ra chuẩn hóa vẫn giữ vấn đề nguồn bằng trạng thái tường minh.

3.2 Schema 1.1 và provenance

Bảng 6: Nhóm metadata phục vụ truy vết; chi tiết đầy đủ tại `docs/DATA_SCHEMA.md`.

Nhóm	Trường điển hình	Vai trò
Định danh	`image_id`, đường dẫn tương đối	ID 24 ký tự từ nguồn/đường dẫn; không phải content hash
Nội dung ảnh	`checksum_sha256`, `image_group_id`	Nhóm trùng byte và kiểm định tệp
Annotation nguồn	`source_annotations`, `source_line`, `source_geometry`	Giữ raw arrays, dòng nguồn và geometry
Annotation chuẩn	`regions`, `ocr_regions`, trường canonical	Tách KIE khỏi transcript toàn trang
Chẩn đoán	Trạng thái image/text/label, `validation_issues`	Tách thiếu, rỗng, không ánh xạ và không hợp lệ

Nguồn: `_normalize_region()`, `_opaque_id()`, schema; [E06].

Giữ provenance cho phép kiểm tra lỗi đến từ nguồn hay chuẩn hóa và sửa có kiểm soát ở giai đoạn sau. ID dựa trên đường dẫn không bảo đảm ẩn danh; transcript và đường dẫn vẫn cần được quản lý như dữ liệu riêng tư.

3.3 Trạng thái thiếu và kiểm định hình học

Schema 1.1 phân biệt `present`, `empty_in_source`, `missing_in_source` cho text; label phân biệt mapped, unmapped và thiếu nguồn. Transcript có thể không có sidecar, rỗng, chỉ có một phần hoặc available; available không bảo đảm polygon hợp lệ. Một vùng sai geometry vẫn được giữ với chẩn đoán chính xác và derived bbox bằng null. [E06]

`validate_polygon()` kiểm số đỉnh, tọa độ hữu hạn, diện tích, đỉnh lặp, tự giao và giới hạn ảnh. `validate_manifest()` kiểm ID/đường dẫn, phiên bản schema, quan hệ source–split, checksum–group, trạng thái text/label, provenance và sự nhất quán geometry/bbox. Do đó `valid=true` có thể cùng tồn tại với annotation nguồn sai đã được mô tả đúng. Tái đối chiếu 6.585 vùng KIE cho thấy nhãn, text và tọa độ giữ nguyên nguồn; đây là tính trung thực chuẩn hóa, không phải chứng nhận ngữ nghĩa. [E12]

3.4 Chia tập xác định và cách ly trùng

`assign_internal_splits()` sắp khóa nhóm SHA-256 rồi trộn bằng `random.Random(42)`. Tỷ lệ dev 0,2 áp dụng cho *số nhóm*, không cam kết đúng 20% số ảnh. Nhóm có cùng content hash không bị chia đôi; một nhóm duy nhất giữ ở train. Với hash thiếu, fallback key được dùng nhất quán nhưng không thể chứng minh danh tính ảnh. [E07]

Bảng 7: Split receipt đang dùng; không thay đổi trong lần lập báo cáo.

Split	Bản ghi	Ý nghĩa
`internal_train`	904	Nguồn train sau cách ly
`internal_dev`	231	Dev nội bộ dùng cho OCR baseline
Nhóm cách ly trùng official	20	Không tham gia hai split nội bộ
`official_validation_inventory`	391	Inventory nguồn; chưa có GT KIE phù hợp
Tổng	1.546	Tách biệt với 6.585 crop recognition

Nguồn: Manifest và `split_summary.json`; tái đếm [E03][E12]. Tên đầy đủ nhóm cách ly: `excluded_duplicate_of_official_validation`.

3.5 Ba chính sách xử lý dữ liệu không hợp lệ

report giữ mọi bản ghi cùng vấn đề nguồn để khảo sát. **skip** loại bản ghi có lỗi ảnh, geometry, parse, mismatch hoặc text/label thiếu theo chính sách; nhãn chưa ánh xạ hay tập KIE rỗng riêng lẻ không đủ để loại. Split được gán trước lọc và không tái cân bằng. **fail** từ chối khi có lỗi thuộc cùng tập điều kiện, CLI trả mã 2 và ghi failure report riêng, giữ bundle thành công cũ. CLI thu thập cả lỗi receipt và crop; API trực tiếp có thể dừng sớm bằng `ValueError`. Không chính sách nào tự sửa nhãn sai nghĩa. [E06][E13]

Hồ sơ hardening trên dữ liệu thật ghi `skip` loại 115 receipt, giữ 1.431 receipt và 6.585 crop; các receipt còn lại giữ nguyên split/provenance. Với `fail`, CLI trả mã 2 và bảo toàn byte của bundle thành công trước đó. Đây là kết quả đã lưu trong `verification.json`, chưa chạy lại hai chính sách trên dữ liệu thật trong lần lập báo cáo. [E11]

3.6 Tính xác định và kiểm định bundle

JSONL dùng UTF-8, sorted keys, LF và strict JSON; không nhúng timestamp hay đường dẫn tuyệt đối máy. Tọa độ nonfinite được giữ dạng chuỗi có chẩn đoán, không tạo literal JSON không chuẩn. Cùng byte đầu vào, thứ tự nguồn, seed, tỷ lệ và môi trường/mã sẽ tạo cùng byte đầu ra. Dòng nguồn lặp có ID phụ thuộc số dòng, nên không hứa bất biến ID khi đổi thứ tự những dòng lặp. [E06]

`--verify-only` kiểm checksum của ba artifact trong report, strict JSON, validation cấu trúc/leakage, split summary và thống kê đầu ra, không đọc lại ảnh raw. Report không chứa hash của chính nó. Cơ chế giúp phát hiện trộn nhầm hoặc hỏng tệp, chưa phải xác thực chống sửa có chủ đích.

Bảng 8: Đối chiếu bundle có sẵn trong lần lập báo cáo.

Bundle / phép kiểm	Kết quả hiện tại	Bối cảnh
`data/processed/`	Cấu trúc đạt 8.131 bản ghi; verify-only từ chối do thiếu artifact checksums	Metadata báo cáo cũ; không tự ghi đè
`goal2_hardening_20261028/run_a/` và `run_b/`	Cả hai verify thành công; bốn tệp byte-identical giữa hai thư mục	Đối chiếu các lần chạy đã tồn tại
Manifest gốc so với run A	Hai JSONL cùng SHA-256; split summary cùng JSON nhưng khác newline	Không trộn hash giữa phiên bản report
Kiểm ảnh nguồn	8.131 ảnh giải mã, kích thước và hash khớp	Đọc trực tiếp lần lập báo cáo

Nguồn: [E11][E12]; tiền tố hai thư mục run là `outputs/audit/`. Không tái chạy preparation.

Kết quả ở Bảng 8 phân biệt hai mức kiểm chứng: manifest gốc đạt cấu trúc; hai bundle hardening đạt thêm kiểm checksum và tính nhất quán bốn tệp. Hash cụ thể được ghi trong phụ lục minh chứng.

3.7 Staging, thay thế và giới hạn rollback

CLI serialize vào thư mục tạm bên trong output, kiểm định bundle đã serialize rồi sao lưu và thay thế lần lượt; validation report được thay cuối. Khi thay thế thông thường phát sinh `OSError`, các tệp đã đổi được phục hồi từ backup. Test tiêm lỗi serialization và từng bước thay thế, cả khi có và chưa có output, đã đạt trong suite hiện tại. [E13]

Đây chưa phải giao dịch nguyên tử bốn tệp. Dừng tiến trình, mất điện, lỗi I/O kéo dài trong rollback hoặc nhiều writer đồng thời nằm ngoài bảo đảm đã kiểm thử. Cần một writer cho mỗi output và verify trước khi sử dụng.

3.8 Đánh giá Goal 2

Goal 2 hoàn thành nền tảng chuẩn hóa có provenance, chia nhóm xác định, xử lý lỗi và kiểm định artifact. Bằng chứng gồm validation cấu trúc, hai bundle hardening trùng byte và kiểm thử rollback; bundle mặc định cũ vẫn cần bổ sung metadata checksum trước khi dùng verifier mới. Chất lượng annotation và gần trùng là các rủi ro dữ liệu còn lại. [E06][E11][E13]

IV. Goal 3: OCR baseline và phân tích lỗi

4.1 Mục tiêu baseline và cấu hình thực tế

Baseline đầu tiên thiết lập đường chạy từ ảnh đến prediction có vị trí, đo tham chiếu và nhận diện vấn đề đánh giá trước các nghiên cứu tiếp theo. Dự án dùng Tesseract với LSTM tiếng Việt trên CPU, không huấn luyện thêm model. Kết quả đánh giá là OCR transcript, không phải trích xuất bốn trường KIE. [E09]

Bảng 9: Cấu hình mã nguồn và runtime artifact hiện có.

Thuộc tính	Giá trị / bằng chứng
Engine runtime	`tesseract v5.5.3.20260724`
Phiên bản trong YAML / lịch sử	5.3.4; khác runtime hiện tại, không ép runtime theo YAML
Thiết bị / ngôn ngữ	CPU; `vie`
Page Segmentation Mode	PSM 6: giả định một khối text đồng nhất
OCR Engine Mode	OEM 1: LSTM
Model	`vie.traineddata`, `tesseract-ocr/tessdata_fast`
Revision đã pin	`87416418657359cb625c412a48b6e1d6d41c29bd`
Đầu ra	TSV: text, word box chữ nhật song song trục, confidence
Môi trường ghi nhận	Python 3.12.16; runtime evaluation ghi Windows và 16 CPU logic

Nguồn: `baseline.py`, `configs/week1.yaml`, runtime và metrics; [E09][E10]. Ý nghĩa PSM/OEM theo tài liệu chính thức [3]; model [4].

Model local được kiểm SHA-256 khớp runtime và downloader:

```
79df64caf7bcfb2a27df5042ecb6121e196eada34da774956995747636d5bfa1
```

Checksum trên đã khớp tệp model và downloader; pin model chưa đồng nghĩa cố định phiên bản Tesseract hoặc hệ điều hành. [E09][E12]

4.2 Inference, word boxes và theo dõi lỗi

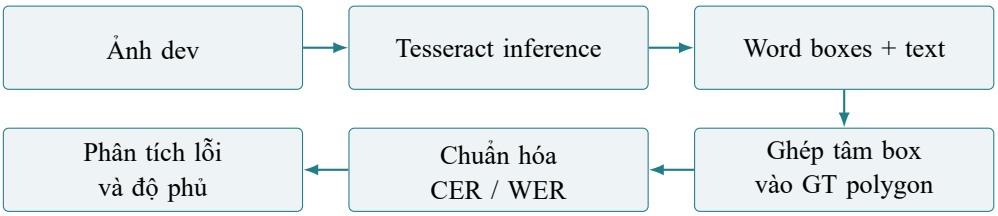
`run_batch()` lọc split, sắp theo `image_id`, chạy từng ảnh và ghi prediction hoặc lỗi riêng. `TesseractBaseline.predict()` kiểm ảnh, gọi executable và đọc TSV trong thư mục tạm. Parser kiểm prefix geometry số và loại dòng trống/geometry không dùng được; confidence nguồn được chia 100 khi không âm. Regression test bảo vệ trước continuation fragments sai định dạng. [E09][E13]

Lỗi inference không được diễn giải thành OCR thành công rỗng. Prediction thành công có thể hợp lệ với danh sách từ rỗng. Word box là đơn vị đầu ra Tesseract, còn GT có thể bao cả dòng hoặc nhóm chữ; sự khác biệt đơn vị này quyết định cách ghép và giới hạn chỉ số.

4.3 Ghép prediction với ground truth

Evaluation nối prediction và manifest bằng `image_id` trên `internal_dev`. Ảnh có transcript GT cần một prediction thành công; thiếu, lỗi hoặc danh sách prediction sai kiểu khiến evaluation dừng. Thành công

với zero words vẫn được đánh giá bằng hypothesis rỗng. GT thiếu geometry hợp lệ hoặc text chuẩn hóa rỗng được loại với bộ đếm riêng. [E10][E13]



Hình 3: Luồng OCR và đánh giá; GT transcript là nguồn annotation độc lập đi vào bước ghép. Nguồn: `inference.py`, `metrics.py` và notebook 04, [E09][E10].

Với từng box dự đoán, lấy tâm từ trung bình tọa độ đỉnh. Nếu tâm nằm trong nhiều polygon GT hợp lệ, chọn polygon có diện tích nhỏ nhất. Trong mỗi vùng GT, sắp các từ theo tọa độ y rồi x, nối bằng dấu cách. Thuật toán hiện tại không tái dựng dòng bằng clustering hoặc thứ tự đọc ngữ nghĩa. Vì vậy sai thứ tự có thể làm tăng edit distance dù một phần từ đã nhận đúng. [E10]

4.4 CER, WER và chuẩn hóa tiếng Việt

Gọi S, D, I lần lượt là số phép thay thế, xóa và chèn trên một căn chỉnh edit distance tối ưu; N là độ dài tham chiếu. Với vùng hợp lệ r, phép cộng micro trên các vùng được định nghĩa:

$$\mathrm{CER}_{\mathrm{micro}} = \frac{\sum_r (S_{c,r} + D_{c,r} + I_{c,r})}{\sum_r N_{c,r}}, \tag{1}$$

$$\mathrm{WER}_{\mathrm{micro}} = \frac{\sum_r (S_{t,r} + D_{t,r} + I_{t,r})}{\sum_r N_{t,r}}. \tag{2}$$

Chỉ số c dùng ký tự Unicode sau chuẩn hóa; t dùng token khoảng trắng. Code tính tổng khoảng cách Levenshtein, chưa xuất riêng phân rã $S/D/I$. NFKC, `casefold()` và gộp whitespace được áp dụng cho cả reference/hypothesis; dấu tiếng Việt và dấu câu được giữ. WER tách theo khoảng trắng nên token thường là âm tiết tiếng Việt, không phải từ đã phân đoạn ngôn ngữ. Micro là chia sau cộng, không phải trung bình CER/WER từng ảnh.

Phép chèn khiến tử số có thể vượt N, nên CER/WER lớn hơn 1 vẫn hợp lệ. Vùng GT không nhận box tạo hypothesis rỗng và lỗi xóa; box ngoài mọi GT được đếm *unassigned* nhưng không trực tiếp đi vào CER/WER. Hai kiểu lệch phủ này cần được đọc cùng chỉ số.

4.5 Kết quả hiện có và số liệu lịch sử

Lần lập báo cáo đọc prediction hiện có và tái chạy `evaluate_ocr_records()` trong bộ nhớ, đối chiếu toàn bộ summary và các dòng per-image/per-region. Không gọi Tesseract và không ghi đè artifact OCR gốc. Kết quả hiện tại khớp hoàn toàn metric local; số liệu lịch sử chỉ có tài liệu mô tả, không có bộ prediction lịch sử riêng để tái tính. [E10][E12]

Bảng 10: Hai bối cảnh đo OCR cần giữ tách biệt.

Đại lượng	Artifact hiện có	Tài liệu lịch sử
Tesseract	5.5.3.20260724	5.3.4
Ảnh internal dev	231	231
Inference thành công	231/231	231/231
Word boxes	26.859	29.849
Vùng GT được đánh giá	8.304	8.304
Loại do geometry GT	104	104
Micro CER (tỷ số)	1,8725	1,8965
Micro WER (tỷ số)	2,1448	2,1795
Vùng GT không được gán box	1.886	1.643
Box ngoài GT hợp lệ	10.488	12.913
Độ trễ trung bình (giây/ảnh)	0,3737	0,500

Nguồn: Hiện có: `runtime.json`, prediction/evaluation [E09][E10], tái kiểm [E12]. Lịch sử: `docs/GOAL3_OCR_BASELINE.md` và `WEEK1_REPORT.md`; chưa xác minh độc lập bộ chạy cũ.

Các tử/mẫu số tái tính là:

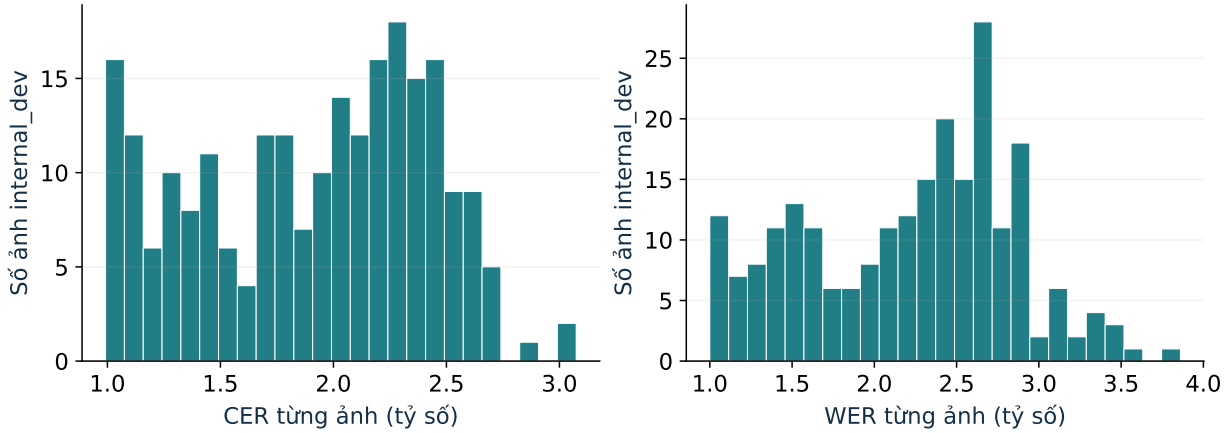
$$\mathrm{CER} = \frac{92.591}{49.449} = 1{,}872454448\ldots, \qquad \mathrm{WER} = \frac{18.332}{8.547} = 2{,}144846145\ldots$$

Runtime ghi tổng inference 86,4131 giây, trung bình 0,373664 giây/ảnh. Đây là metadata của lần chạy đã lưu, chưa phải benchmark tốc độ giữa các máy. Số CPU logic/platform trong metric do tiến trình evaluation ghi nhận. [E09][E10]

Hai cột của Bảng 10 khác phiên bản engine và chưa có đủ artifact riêng cho bộ chạy lịch sử; không suy ra cải thiện mô hình từ chênh lệch này. Phiên bản 5.3.4 trong YAML mô tả cấu hình dự kiến, còn runtime hiện có ghi 5.5.3.20260724.

Cách diễn giải. CER/WER hiện tại mang tính chẩn đoán và phụ thuộc protocol ghép vùng. Độ phủ annotation, chất lượng transcript, vị trí polygon và thứ tự từ đều có thể ảnh hưởng; chưa phải phép đo riêng, có thể so sánh độc lập về khả năng nhận dạng của Tesseract.

4.6 Phân bố lỗi và các nguồn sai khác



Hình 4: Phân bố CER/WER từng ảnh trên 231 ảnh dev từ artifact đã tái đối chiếu; giữ đầy đủ giá trị, không cắt đuôi. Đây là chỉ số theo protocol vùng, không phải phân bố lỗi thuần nhận dạng. Nguồn [E10][E12].

Hình 4 cho thấy sai khác không đồng đều giữa ảnh, bổ sung thông tin mà một giá trị micro chưa thể hiện. Notebook 04 cung cấp overlay GT/word boxes và so transcript cho ca trung vị/lỗi cao; output lưu sẵn hỗ trợ khảo sát nhưng chưa tạo taxonomy nguyên nhân có nhãn người review. [E14]

Bảng 11: Phân biệt nguyên nhân có thể ảnh hưởng phép đo; không gán tỷ trọng nhân quả.

Nguồn sai khác	Bằng chứng hiện có	Giới hạn kết luận
Nhận dạng OCR	Prediction chứa text/confidence; CER/WER ghi sai khác sau ghép với GT	Chưa tách lỗi nhận dạng khỏi lỗi GT/alignment bằng review từng ca
Ghép vùng / thứ tự	1.886 GT không nhận box; 10.488 box unassigned; sắp y rồi x	Chưa thể gọi mọi ca là OCR bỏ sót/false positive
Ground truth	104 vùng dev bị loại geometry; audit nguồn có sai text/nhãn/vị trí	Audit KIE không tự chứng minh lỗi OCR GT cùng vùng
Độ phủ / protocol	GT vùng lớn hơn word boxes; box unassigned đếm riêng	CER/WER không bao phủ mọi text prediction trên trang

Nguồn: [E05][E10][E12]; các nguyên nhân có thể chồng lấp, chưa có tỷ lệ phân rã được xác minh.

4.7 Đánh giá Goal 3

Inference đã có bằng chứng hoàn thành trên toàn bộ 231 ảnh dev, prediction và metric truy vết được, evaluation chặn dữ liệu thiếu, có công cụ xem lỗi. Đây là phạm vi hoàn thành một baseline Tesseract đầu tiên. Chưa đánh giá mô hình KIE được huấn luyện; không có field extraction accuracy hay field-level F1.

Detection precision/recall/F1 được ghi `N/A` vì GT theo dòng/vùng và prediction theo từ. Ghép 1:1 bằng IoU sẽ trộn mức chia vùng với khả năng phát hiện. Tham số IoU 0,5 chỉ lưu trong metadata, không điều khiển CER/WER hiện tại; cần protocol và GT tương thích trước khi so mô hình. [E10]

V. Tổng hợp kiểm thử và kiểm chứng

5.1 Kiểm chứng thực hiện trong lần lập báo cáo

Lần chạy kiểm thử khi lập hồ sơ báo cáo dùng Windows/Python 3.12.16 tại commit `4ee2776`, với fixture tổng hợp. Kết quả **106 passed trong 1,90 giây**, không có test fail; không chạy lại suite trong các lượt biên tập sau đó. Log và lệnh đầy đủ nằm tại `evidence/pytest.txt` và `repository_context.json`. [E13]

Bảng 12: Tóm tắt phương pháp và kết quả kiểm chứng hiện tại.

Thành phần	Phương pháp	Kết quả	Nguồn
Goal 1	Đếm manifest, ảnh nguồn, nhãn và CSV review	Inventory/EDA khớp; review 40 dòng, không review lại pixel	[E12]
Goal 1	Đối chiếu JSONL gần trùng và summary	36 cặp; chưa phân xử, không tái băm	[E08]
Goal 2	Decode, kích thước, SHA-256 và validation	8.131 bản ghi đạt cấu trúc và khớp ảnh	[E12]
Goal 2	So run A/B và gọi verifier	Bốn tệp bằng byte; hai bundle verify thành công	[E12]
Goal 2	Verify bundle gốc	Từ chối metadata thiếu checksums, không sửa output	[E12]
Goal 2	Kiểm leakage SHA-256 trên receipt/crop	0 nhóm đi qua active split	[E12]
Goal 3	Kiểm prediction, tái tính evaluation	231 ảnh, 26.859 boxes; summary và chi tiết khớp	[E12]
Dự án	Suite tests hiện có	106 đạt, dữ liệu tổng hợp	[E13]
Notebook	Đọc code/output lưu sẵn, kiểm cú pháp cells	4 tệp có output, không error output; chưa thực thi lại	[E14]

Kiểm tra Goal 2 bao gồm hồi phục khi serialization/thay thế lỗi, source/output statistics, policy và phát hiện artifact trộn/hỏng. Goal 3 có test Unicode giữ dấu, token khoảng trắng, alignment, prediction rỗng thành công và từ chối thiếu prediction. Tests này bảo vệ hành vi mã, không trực tiếp đo chất lượng trên ảnh thật.

5.2 Kết quả lịch sử và trạng thái CI

Tài liệu ghi 24, 60 và 104 tests ở các giai đoạn trước; đây là các mốc suite khác nhau, không cộng dồn. Workflow dùng Ubuntu/Python 3.12 và dependency khóa, không cần MC-OCR. Kết quả local 106 tests không xác nhận CI thành công: hồ sơ truy vấn status chưa có log/check-run đủ căn cứ, nên **trạng thái CI chưa xác minh**. [E01][E13][E15]

VI. Thảo luận, kết luận và hướng tiếp theo

6.1 Quan hệ giữa ba mục tiêu

Goal 1 xác định cần đo gì và nguồn nào có thể làm GT. Việc phân biệt vùng KIE, transcript toàn trang và crop recognition ngăn sai giả định đầu vào; audit cho thấy rủi ro không chỉ ở ảnh mà còn ở annotation. Goal 2 biến hiểu biết đó thành hợp đồng dữ liệu: giữ provenance, biểu diễn thiếu/lỗi riêng, chia nhóm

chống trùng byte và công bố artifact có kiểm định. Goal 3 dùng chính nền tảng này để chạy một baseline và làm lộ ra khoảng cách giữa đơn vị GT với đơn vị prediction.

Giá trị kỹ thuật của tuần đầu nằm ở khả năng truy nguyên. Khi metric cao bất thường, có thể lần từ numerator/denominator đến vùng và prediction cụ thể thay vì đổ mọi sai khác cho engine OCR. Khi validation đạt, vẫn biết 115 hóa đơn có geometry nguồn bất thường vì trạng thái cấu trúc và chất lượng nguồn không bị gộp. Khi số liệu tài liệu khác artifact, checksum và metadata giúp ghi nhận chính xác phạm vi được xác minh. [E03][E10][E12]

6.2 Những giới hạn còn lại

1. **Danh tính giao dịch:** 36 ứng viên gần trùng chưa phân xử; pHash không bảo đảm phát hiện mọi ảnh cùng giao dịch. Không có kết luận benchmark hết leakage gần trùng.
2. **Chất lượng annotation:** nhãn, text, vị trí và loại chứng từ còn sai/bất định. Mẫu audit không đại diện toàn tập; bản ghi không có nhãn không đồng nghĩa trường vắng trên ảnh.
3. **Phép đo OCR:** GT và word boxes khác độ hạt; coverage và thứ tự ghép ảnh hưởng edit distance. Chưa có phân rã nhân quả định lượng OCR/GT/alignment.
4. **Tái lập theo môi trường:** model được pin nhưng runtime hiện tại khác phiên bản ghi trong YAML/lịch sử. Bundle gốc thiếu checksum metadata; so bốn tệp lặp chỉ được xác minh trên các bundle hardening có sẵn.
5. **Phạm vi chức năng:** không có mô hình KIE đã huấn luyện, metric trường, API, UI hay bộ kiểm tra nghiệp vụ đã nghiệm thu. Quan hệ parent receipt của crop riêng chưa được thiết lập.

6.3 Kết luận

Ba mục tiêu tuần 1 đạt deliverable trong phạm vi nghiên cứu ban đầu: inventory và EDA có kiểm tra nguồn, audit annotation có hồ sơ, pipeline chuẩn hóa/chia tập/validation có bằng chứng tái lập, OCR baseline có prediction và evaluation đối chiếu được. Kết quả 106 tests đạt hỗ trợ tính đúng của hành vi hiện tại; 8.131 ảnh khớp manifest hỗ trợ tính toàn vẹn dữ liệu. Các kết luận không mở rộng thành chất lượng annotation hoàn hảo, hiệu năng OCR sản xuất hay thành công KIE.

6.4 Hướng tiếp theo theo bàn giao Week 2

Theo `docs/WEEK2_HANDOFF.md`, bước sau ưu tiên target KIE từ nhãn được xác minh, giữ quarantine và đánh giá ở mức hóa đơn, phân xử gần trùng và hiệu chỉnh protocol GT–prediction trước so mô hình. Review 40 ảnh đã hoàn tất; cần xử lý các ca bất định còn lại, đồng thời giữ provenance và bất định của OCR. Đây là định hướng tiếp nối, chưa phải kết quả tuần 1. [E02][E05]

Tài liệu tham khảo

[1] MC-OCR Challenge. *Mobile captured receipts OCR: mô tả tác vụ IQA và KIE*. Trang chính thức, truy cập ngày 28/10/2026. https://www.rivf2021-mc-ocr.vietnlp.com/

[2] MC-OCR Challenge. *Dataset: định dạng dữ liệu và annotation*. Truy cập ngày 28/10/2026. https://www.rivf2021-mc-ocr.vietnlp.com/dataset

[3] Tesseract OCR. *Command Line Usage*. Tài liệu chính thức: OEM, PSM và TSV, truy cập ngày 28/10/2026. https://tesseract-ocr.github.io/tessdoc/Command-Line-Usage.html

[4] Tesseract OCR. *tessdata_fast*, revision `8741641`. Model tiếng Việt được pin trong dự án; kiểm tra trang revision ngày 28/10/2026. https://github.com/tesseract-ocr/tessdata_fast/tree/8741641 8657359cb625c412a48b6e1d6d41c29bd

[5] DocuCheck AI. *Kho mã và tài liệu kỹ thuật Week 1*. Mốc mã nguồn `4ee2776`; notebook và artifact cục bộ được phân biệt trong phụ lục. https://github.com/AIVIETNAM-AIO-Heart208/DocuCheck-AI

Ghi chú về nguồn và phân phối

Các tài liệu web trên được tham khảo cho mô tả dataset và cấu hình engine; số liệu thực nghiệm của báo cáo lấy từ repository/artifact cục bộ, không lấy từ tổng số công bố của cuộc thi. Không sử dụng bài báo, DOI hay tác giả chưa kiểm chứng. Trích dẫn implementation dùng mã E và đường dẫn/hàm ở phụ lục để người đọc nối trực tiếp đến mã nguồn.

Source LaTeX và hình tổng hợp đủ để biên dịch PDF; tái kiểm số liệu cần thêm artifact cục bộ và quyền truy cập dataset. Danh mục tệp cần cung cấp riêng nằm ở phụ lục.

PHỤ LỤC – DANH MỤC MINH CHỨNG

Ký hiệu phân phối: **S** = mã/tài liệu đang được Git theo dõi; **L** = artifact local bị ignore, có thể chứa dữ liệu riêng tư; **R** = tệp tổng hợp tạo cho báo cáo. "Kiểm chứng" ở đây theo phép kiểm mô tả, không thay review pixel hoặc lần chạy lịch sử.

Bảng 13: Ánh xạ hoạt động và kết quả đến nguồn thực tế.

Mã	Goal / nội dung	Đường dẫn hoặc hàm	Trạng thái
E01	Mốc mã, lịch sử	`docs/WEEK1_REPORT.md`; `evidence/repository_context.json`; `evidence/artifact_manifest.csv`	S/R; mốc và hash đã kiểm
E02	Phạm vi, định hướng	`README.md`; `docs/idea.md`; `docs/WEEK2_HANDOFF.md`	S; nội dung đã đọc
E03	Goal 1: inventory, annotation	`data/processed/manifest.jsonl`; `recognition_manifest.jsonl`; `validation_report.json`; `src/docucheck/data/loader.py`	S/L; tái đếm, đọc ảnh, đối chiếu nguồn
E04	Goal 1: EDA và chọn mẫu	`src/docucheck/data/eda.py`: `collect_image_features()`, `select_annotation_audit_sample()`; notebook 01/02	S; tính lại EDA, tái tạo mẫu
E05	Goal 1: review 40 ảnh	`outputs/audit/week1/annotation_review.csv`; `annotation_sample.jsonl`; `docs/ANNOTATION_AUDIT.md`	S/L; kiểm CSV, chưa review lại pixel
E06	Goal 2: chuẩn hóa, policy	`docs/DATA_SCHEMA.md`; `src/docucheck/data/preprocessing.py`: `prepare_records()`; `validation.py`: `validate_manifest()`; `scripts/prepare_dataset.py`	S; đọc mã, tests đạt
E07	Goal 1/2: split, quarantine	`src/docucheck/data/splitting.py`: `assign_internal_splits()`, `find_cross_split_duplicate_groups()`; `data/processed/split_summary.json`	S/L; đếm và kiểm exact leakage
E08	Goal 1: 36 cặp ứng viên	`outputs/audit/week1/near_duplicate_candidates.jsonl`; `near_duplicate_summary.json`; `near_duplicate_failures.jsonl`; `src/docucheck/data/duplicates.py`	S/L; kiểm artifact, chưa tái băm/phân xử
E09	Goal 3: engine, inference	`src/docucheck/ocr/baseline.py`: `TesseractBaseline`; `inference.py`: `run_batch()`; `scripts/run_ocr.py`; `scripts/download_ocr_model.py`; `configs/week1.yaml`; `outputs/ocr/tesseract_internal_dev/runtime.json`	S/L; đọc mã, runtime, kiểm model hash
E10	Goal 3: prediction, metric	`outputs/ocr/tesseract_internal_dev/predictions.jsonl`; `failures.jsonl`; `outputs/ocr/evaluation/metrics.json`; `per_image_metrics.jsonl`; `per_region_alignment.jsonl`; `src/docucheck/evaluation/metrics.py`: `evaluate_ocr_records()`; `scripts/evaluate_ocr.py`	S/L; tái tính khớp, không inference lại

PHỤ LỤC / DANH MỤC MINH CHỨNG (TIẾP THEO)

Bảng 13 (tiếp theo). Hoạt động và nguồn hỗ trợ.

Mã	Goal / nội dung	Đường dẫn hoặc hàm	Trạng thái
E11	Goal 2: real-data hardening	`outputs/audit/goal2_hardening_20261028/verification.json`; `verify_real_data.py`; bốn artifact trong `run_a/`, `run_b/`, `run_skip/`	L; kiểm run A/B; skip/fail real-data là hồ sơ lịch sử
E12	Kiểm chứng báo cáo	`verify_evidence.py`; `evidence/verified_summary.json`; `evidence/artifact_manifest.csv`; `figures/*.pdf`	R; số liệu tổng hợp và hash đã tạo thật
E13	Tests và rollback	`tests/test_prepare_dataset_cli.py`; `test_preprocessing.py`; `test_annotation_validation.py`; `test_splitting.py`; `test_ocr_metrics.py`; toàn suite; `evidence/pytest.txt`	S/R; 106 đạt local, 28/10/2026
E14	Notebook và visualization	`notebooks/01_dataset_audit.ipynb`; `02_exploratory_data_analysis.ipynb`; `03_preprocessing_validation.ipynb`; `04_ocr_baseline_evaluation.ipynb`; `src/docucheck/visualization/receipt.py`	S; workspace có edits sẵn, không thực thi lại
E15	CI	`.github/workflows/tests.yml`; `evidence/ci_status.json`	S/R; workflow đã đọc; status rỗng, chưa xác minh run

Tệp cần đi kèm khi nộp

Nộp PDF cùng source LaTeX, hai hình tổng hợp và hồ sơ trong `evidence/`; kèm `EVIDENCE_INDEX.md`, `BUILD.md`, `SUBMISSION_CHECKLIST.md`. Cung cấp repository tại commit đã ghi và bản notebook workspace đúng checksum để kiểm tra implementation.

Để tái kiểm sâu số liệu, cần cung cấp có kiểm soát hai manifest, bundle hardening A/B, worksheet review, near-duplicate artifacts và bộ OCR prediction/runtime/evaluation liệt kê ở E03/E05/E08/E10/E11. Các tệp này đang có local nhưng chưa được đóng gói công khai cùng báo cáo. Không tự kèm raw dataset; người chấm muốn tái tính đặc trưng ảnh cần quyền truy cập dataset phù hợp điều khoản.

Bằng chứng còn thiếu hoặc chưa được tái xác minh

Chưa có snapshot riêng của bộ OCR 5.3.4 lịch sử, log CI/check-run thành công, quyết định phân xử 36 cặp gần trùng, liên kết parent receipt cho crop hoặc taxonomy nguyên nhân OCR có nhãn người review. Review trực quan 40 ảnh là hồ sơ có sẵn, chưa lặp lại trong lần lập báo cáo. Các mục này cần được phân biệt với những kết quả đã tái tính trong E12.