AI-VIETNAM

KHÓA HỌC AIO2026

BÁO CÁO TIẾN ĐỘ TUẦN 1

Submission I – Module 05

DocuCheck AI

Hệ thống xử lý và kiểm tra tài liệu

Hiểu dữ liệu, xử lý tái lập và OCR baseline

Tên nhóm	Winner Winner Chicken Dinner
Thành viên 1	Nguyễn Văn Minh
Thành viên 2	Nguyễn Thành Trung

Ngày lập báo cáo: 28 tháng 10 năm 2026

github.com/AIVIETNAM-AIO-Heart208/DocuCheck-AI

Tóm tắt

DocuCheck AI hướng tới đọc thông tin trên ảnh biên lai tiếng Việt và cho phép người dùng kiểm tra lại kết quả trên ảnh gốc. Trong tuần đầu, nhóm tập trung vào ba việc: tìm hiểu dữ liệu, chuẩn bị quy trình xử lý có thể lặp lại và thiết lập một mốc OCR ban đầu.

Nhóm đã khảo sát 1.546 bản ghi biên lai, phân tích chất lượng ảnh và rà soát thủ công 40 ảnh được chọn để tìm rủi ro. Dữ liệu đã được chuẩn hóa, chia tập và kiểm tra để hạn chế ảnh trùng giữa các tập. Trên 231 ảnh đánh giá nội bộ, Tesseract đã tạo kết quả nhận dạng cho toàn bộ ảnh. Kết quả này giúp nhóm thấy rõ những khó khăn của cả dữ liệu lẫn cách đánh giá OCR; chưa đủ để kết luận chất lượng trích xuất thông tin tự động.

I. Mục tiêu và phạm vi tuần 1

Ảnh biên lai thường có ánh sáng không đều, chữ nhỏ, giấy nhăn hoặc nền phức tạp. Dự án đặt mục tiêu xác định bốn thông tin chính: tên nơi bán, địa chỉ, thời điểm giao dịch và tổng tiền. Mỗi thông tin cần gắn với vị trí trên ảnh để người dùng có thể kiểm tra lại. Trong tuần 1, nhóm xây dựng nền dữ liệu và OCR ban đầu cho mục tiêu đó [1, 3].

Đây là báo cáo tiến độ nghiên cứu. Nhóm chưa huấn luyện mô hình trích xuất bốn trường thông tin, chưa đánh giá độ chính xác theo từng trường và chưa hoàn thành ứng dụng cho người dùng.

II. Kết quả 1: Hiểu dữ liệu biên lai

2.1 Quy mô và đặc điểm dữ liệu

Bản dữ liệu MC-OCR đang sử dụng gồm 1.155 bản ghi ảnh biên lai train (tập phát triển mô hình) và 391 bản ghi validation chính thức (tập kiểm định do nguồn dữ liệu cung cấp). Bản validation hiện có không kèm nhãn cho bốn trường thông tin, nên chưa dùng để chấm chất lượng trích xuất. Phần train có 6.585 vùng gán nhãn cho các trường cần tìm. Ngoài ra còn có bản chép chữ tham chiếu (transcript) toàn trang và một bộ 6.585 ảnh cắt nhỏ dành riêng cho nhận dạng chữ. Nhóm giữ các nguồn này tách biệt vì chưa xác minh được liên kết giữa ảnh cắt nhỏ với biên lai gốc.

Bảng 1: Quy mô dữ liệu nhóm đã khảo sát.

Thành phần	Số lượng
Bản ghi biên lai	1.546
Bản ghi biên lai thuộc tập train	1.155
Ảnh validation chính thức	391
Vùng thông tin được gán nhãn trên ảnh train	6.585
Vùng transcript toàn trang	40.868
Ảnh cắt nhỏ cho tác vụ nhận dạng chữ riêng	6.585

Các bản ghi không hoàn toàn là ảnh khác nhau: 1.546 bản ghi biên lai tương ứng 1.491 nội dung tệp ảnh duy nhất; riêng train có 1.122 nội dung duy nhất. Vì vậy, đếm bản ghi phù hợp để mô tả dữ liệu đầu vào, còn chia tập cần xét nhóm nội dung trùng để tránh đánh giá trên ảnh đã xuất hiện ở tập phát triển.

Số vùng gán nhãn không đồng nghĩa số ảnh: một ảnh có thể có nhiều vùng cho cùng một trường. Bảng 2 cho thấy phân bố bốn trường trong 1.155 ảnh train. Có 947 ảnh được gán đủ bốn loại trường và hai ảnh có danh sách nhãn rỗng. Một vùng còn lại mang nhãn nguồn chưa ánh xạ vào bốn trường, được giữ riêng thay vì tự suy đoán loại thông tin.

Bảng 2: Phân bố nhãn trường trên 1.155 bản ghi train. Mỗi ảnh được đếm một lần cho từng trường có mặt trong annotation.

Trường thông tin	Số vùng	Ảnh có nhãn	Ảnh chưa có nhãn
Tên nơi bán	1.171	1.071	84
Địa chỉ	1.952	1.077	78
Thời điểm giao dịch	1.347	1.088	67
Tổng tiền	2.114	1.081	74

Số vùng tổng tiền nhiều hơn số vùng tên nơi bán, nhưng số ảnh có nhãn khá gần nhau. Vì vậy, cần đánh giá cả mức vùng và mức biên lai. Đồng thời, *chưa có nhãn* không đồng nghĩa thông tin không xuất hiện trên ảnh: cần phân biệt trường vắng mặt, không đọc được và chưa được gán.

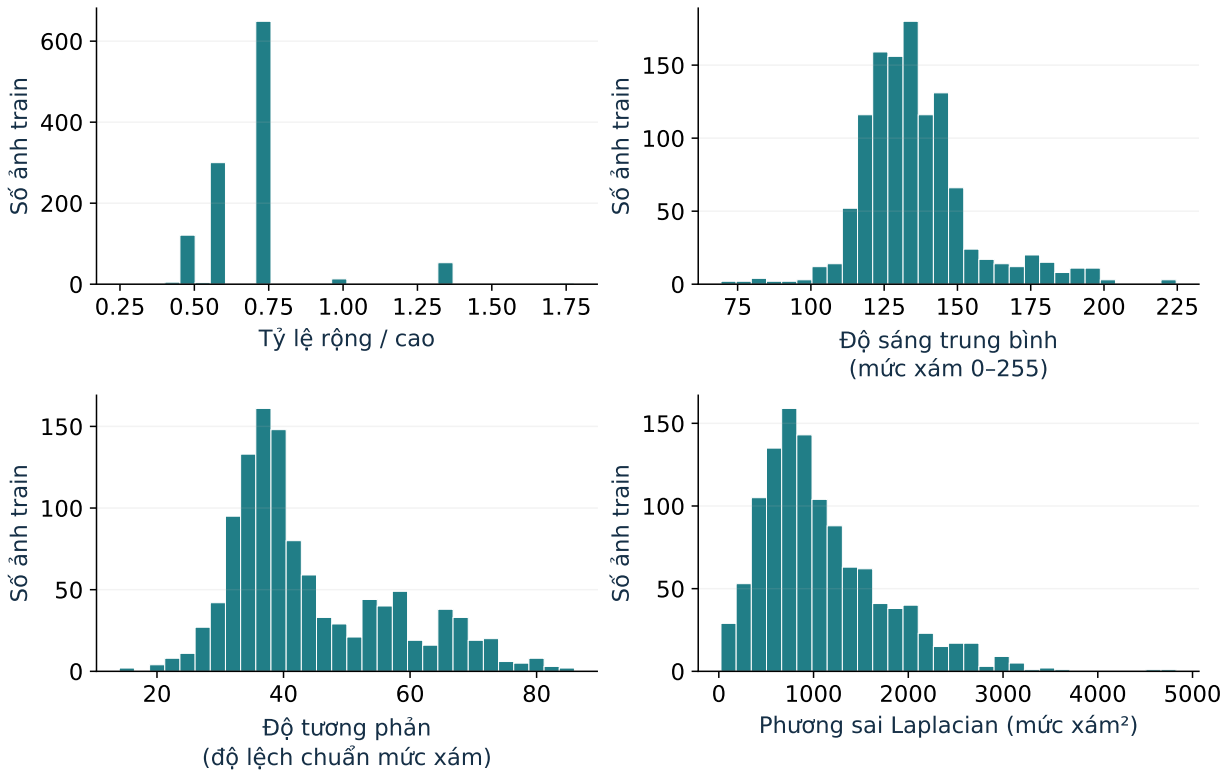
Bản chép chữ toàn trang có ở 1.151 ảnh train, với tổng cộng 40.868 vùng chữ. Đây là nguồn tham chiếu cho OCR; nhãn bốn trường phục vụ tác vụ trích xuất thông tin, gọi tắt là KIE. Việc rà soát KIE không tự xác nhận toàn bộ transcript OCR là đúng.

2.2 Đặc điểm ảnh và ý nghĩa đối với xử lý

Chiều rộng ảnh train nằm trong khoảng 352–1.024 pixel, chiều cao 480–2.860 pixel. Có 1.099 ảnh dọc hoặc vuông và 56 ảnh ngang; trung vị tỷ lệ rộng/cao là 0,75. Sự thay đổi tỷ lệ hình dạng trong Hình 1 cho thấy cần kiểm tra các ảnh dài, hẹp và ảnh ngang khi lựa chọn cách đổi kích thước hoặc phân đoạn. Ép mọi ảnh về một tỷ lệ cố định có thể làm biến dạng chữ; đây là rủi ro cần kiểm tra, chưa phải kết quả so sánh các phương pháp tiền xử lý.

Độ sáng trung bình ảnh xám thay đổi từ khoảng 69,3 đến 224,6 trên thang 0–255, trung vị 133,0; độ tương phản, đo bằng độ lệch chuẩn mức xám, nằm trong khoảng 14,0–86,0. Các phân bố này giúp chọn cả ảnh tối, sáng và ít tương phản để rà soát, thay vì chỉ xem những ảnh có vẻ điển hình. Phương sai Laplacian đo biến thiên chi tiết ảnh và có thể hỗ trợ tìm ảnh cần kiểm tra độ nét, nhưng còn chịu ảnh hưởng của nền và cạnh giấy. Các chỉ số này không phải điểm chất lượng OCR, cũng chưa đủ để đặt ngưỡng tự động loại ảnh.

Mật độ nhãn cũng thay đổi: trung vị là năm vùng KIE mỗi ảnh, nhỏ nhất không có vùng và lớn nhất 29 vùng. Do đó, số vùng lớn có thể phản ánh nhiều phần thông tin hoặc cách gán nhãn cần rà soát; không nên tự động hiểu là ảnh có đầy đủ nhãn hơn.



Hình 1: Phân bố hình dạng, độ sáng, tương phản và mức biến thiên chi tiết của 1.155 ảnh train.

2.3 Rà soát nhãn và ảnh trùng

Nhóm rà soát 40 ảnh được chọn có chủ đích, ưu tiên ảnh có cảnh báo về nhãn, hình học hoặc chất lượng ảnh. Kết quả ghi nhận 6 ảnh được đánh giá đúng, 32 ảnh có ít nhất một vấn đề và 2 ảnh chưa thể kết luận. Những vấn đề thường gặp gồm thiếu vùng cần gán nhãn, nhãn sai hoặc vị trí vùng không khớp nội dung trên ảnh. Ngoài các nhóm trong Bảng 3, rà soát còn phát hiện nội dung chép chữ sai dù loại trường và vị trí vùng đúng; vì vậy sửa nhãn cần kiểm tra cả giá trị chữ.

Bảng 3: Một số vấn đề ghi nhận khi rà soát 40 ảnh.

Vấn đề	Số ảnh	Ví dụ về tác động
Thiếu nhãn cho thông tin nhìn thấy	21	Mô hình có thể học từ dữ liệu chưa đầy đủ
Gán sai loại thông tin	8	Tên nơi bán có thể bị hiểu thành trường khác
Vùng đánh dấu sai vị trí	6	Chữ trong vùng không khớp giá trị cần lấy
Chữ khó đọc	3	Cần kiểm tra thủ công hoặc xử lý ảnh tốt hơn

Các nhóm vấn đề có thể trùng trên cùng một ảnh. Mẫu 40 ảnh được ưu tiên để tìm lỗi, nên tỷ lệ 32/40 không đại diện cho toàn bộ dữ liệu.

Ba tình huống đã được xác nhận trong lượt rà soát giúp làm rõ tác động của các lỗi trên:

1. **Sai loại thông tin:** một vùng chứa ngày/giờ được gán thành địa chỉ. Vùng có thể bao đúng chữ nhưng vẫn tạo tín hiệu huấn luyện sai về ý nghĩa trường. Cần phân xử loại thông tin và sửa nhãn trong phiên bản có lưu lịch sử.

2. **Vùng bao không đủ tên nơi bán:** một số chú thích chỉ khoanh một phần tên. Nếu dùng vùng đó để cắt ảnh, nội dung huấn luyện có thể mất chữ dù đa giác vẫn hợp lệ về hình học. Cần kiểm tra phạm vi trên ảnh và vẽ lại vùng sau xác nhận.
3. **Sai giá trị chép chữ:** có trường hợp giá trị tiền trong annotation khác nội dung nhìn thấy trên ảnh. Sửa loại trường hoặc vị trí không giải quyết được lỗi này; cần kiểm tra và hiệu chỉnh text riêng. Đây là lỗi annotation KIE đã quan sát, không tự chứng minh transcript OCR toàn trang mắc cùng lỗi.

Hai ảnh chưa thể kết luận cũng có ý nghĩa: ảnh quá nhòe có thể không đủ căn cứ xác nhận trường thiếu; một số báo cáo tổng kết có ngày và tổng tiền khác nghĩa với giao dịch bán lẻ. Các trường hợp này cần quy ước phạm vi hoặc giữ trạng thái bất định, thay vì ép thành đúng/sai để hoàn tất thống kê.

Kiểm tra tự động trên toàn tập còn ghi nhận 115 bản ghi biên lai có vùng chú thích sai hình học: sáu ảnh có vùng nhãn trường bị tự giao và 109 ảnh khác có vùng transcript vượt biên ảnh. Đây là lỗi hình học của chú thích nguồn, khác với việc vùng đánh dấu không khớp chữ được phát hiện khi xem ảnh. Các lỗi được ghi nhận kèm dữ liệu; nhãn gốc chưa được sửa.

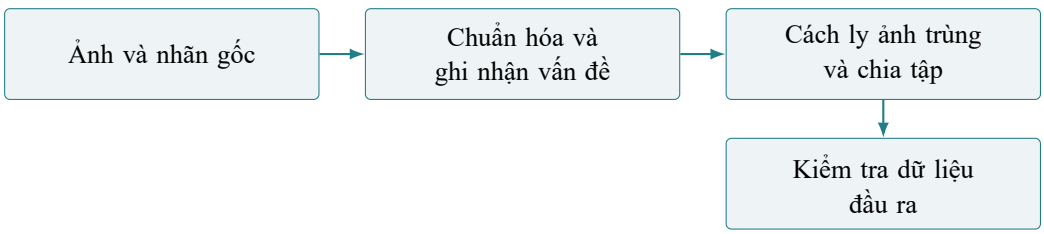
Nhóm phát hiện 20 bản ghi train trùng chính xác với ảnh trong tập validation chính thức và đã cách ly chúng khỏi tập huấn luyện, đánh giá nội bộ. Có thêm 36 cặp ảnh gần giống cần xem lại bằng mắt để xác định có cùng giao dịch hay không. Kết quả hiện tại giúp giảm nguy cơ đánh giá lạc quan do ảnh trùng; chưa thể khẳng định đã tìm hết mọi trường hợp gần trùng.

III. Kết quả 2: Chuẩn bị dữ liệu cho các bước tiếp theo

3.1 Chuẩn hóa và giữ thông tin nguồn

Nhóm đã xây dựng quy trình đọc ảnh và nhãn, chuẩn hóa về cùng một cấu trúc, ghi lại các vấn đề của dữ liệu gốc và chia tập theo nhóm ảnh trùng chính xác. Mỗi bản ghi lưu mã ảnh, kích thước, nguồn dữ liệu, vùng chữ, nhãn trường và tập được phân vào; các trạng thái thiếu nhãn, nhãn rỗng hoặc vùng lỗi được ghi riêng. Dữ liệu gốc được giữ nguyên để có thể đối chiếu khi cần. Tổng cộng 8.131 bản ghi ảnh, gồm 1.546 biên lai và 6.585 ảnh cắt nhỏ, đã qua kiểm tra cấu trúc; ảnh tương ứng cũng được đọc, kiểm tra kích thước và mã băm nội dung.

Ví dụ, nhãn nguồn chỉ tên nơi bán được ánh xạ sang một trường thống nhất, đồng thời giữ nhãn ban đầu, nội dung chữ, tọa độ và nguồn annotation. Nhãn lạ chưa xác định được nghĩa sẽ được đánh dấu chưa ánh xạ; một danh sách nhãn rỗng vẫn được phân biệt với nguồn không cung cấp nhãn. Cách lưu này giúp sửa lỗi sau khi phân xử mà còn đối chiếu được với dữ liệu ban đầu, thay vì âm thầm thay đổi ý nghĩa của nguồn.



Hình 2: Quy trình chuẩn bị dữ liệu đã hoàn thành trong tuần 1.

3.2 Chia tập và ngăn trùng chính xác

Sau khi cách ly ảnh train trùng validation chính thức, các ảnh có cùng nội dung tệp được gom theo mã băm SHA-256 và luôn ở cùng một tập. Nhóm dành khoảng 20% số nhóm cho dev nội bộ (tập đánh giá trong quá trình phát triển), với hạt giống ngẫu nhiên cố định là 42. Tỷ lệ áp dụng theo nhóm nên số bản ghi không nhất thiết đúng 80/20. Kết quả chia tập trong Bảng 4 không còn nhóm trùng chính xác đi qua các tập đang sử dụng.

Bảng 4: Kết quả chia 1.546 bản ghi biên lai.

Nhóm	Số ảnh	Vai trò
Train nội bộ	904	Dữ liệu cho bước phát triển mô hình
Dev nội bộ	231	Dữ liệu đánh giá OCR ban đầu
Cách ly do trùng validation	20	Không dùng để huấn luyện hoặc đánh giá nội bộ
Validation chính thức	391	Tập ảnh được giữ riêng
Tổng cộng	1.546	

3.3 Kiểm tra tính nhất quán và xử lý dữ liệu lỗi

Quy trình cho phép giữ lại bản ghi kèm cảnh báo, bỏ bản ghi lỗi hoặc dừng khi gặp lỗi. Các số liệu trên thuộc phương án giữ lại kèm cảnh báo, nên chưa phải bộ dữ liệu đã làm sạch toàn bộ nhãn. Nếu chọn bỏ lỗi, việc lọc diễn ra sau chia tập và giữ phân nhóm ban đầu của các ảnh còn lại; quy trình không tự cân bằng lại số lượng.

Hai lần chuẩn bị dữ liệu với cùng đầu vào và cấu hình đã cho kết quả đầu ra giống hệt nhau. Phép kiểm đầu ra đối chiếu nội dung, số bản ghi và phân nhóm để phát hiện bộ kết quả bị thiếu, thay đổi hoặc trộn phiên bản. Kết quả kiểm thử tự động cục bộ cũng ghi nhận 106 trường hợp đạt. Những phép kiểm này hỗ trợ tính nhất quán của quy trình, nhưng không thay thế kiểm tra ngữ nghĩa: một bản ghi hợp lệ về cấu trúc vẫn có thể được gán sai nội dung.

IV. Kết quả 3: OCR ban đầu và bài học rút ra

4.1 Lựa chọn baseline và cấu hình đánh giá

Nhóm sử dụng Tesseract để nhận dạng chữ và vị trí trên ảnh (OCR) [2]. Công cụ có mô hình tiếng Việt sẵn, chạy được trên CPU và trả về vị trí cùng chữ nhận dạng, phù hợp để thiết lập mốc ban đầu mà chưa cần huấn luyện thêm. Lựa chọn này phục vụ khảo sát đường xử lý và phép đo; tuần 1 chưa có thí nghiệm so sánh để xác định engine tốt nhất cho dữ liệu này.

Lần chạy được đánh giá dùng phiên bản 5.5.3.20260724, mô hình tiếng Việt thuộc bộ *tessdata fast*, với chế độ phân đoạn trang PSM 6 (coi ảnh là một khối chữ) và bộ nhận dạng LSTM (OEM 1). Giả định một khối chữ cần được kiểm tra đối với biên lai có nhiều cột hoặc nhiều hướng chữ; hiện chưa có so sánh chế độ phân đoạn để xác nhận tác động đó trên tập này.

Trên toàn bộ 231 ảnh dev nội bộ, chương trình tạo kết quả cho 231 ảnh, với 26.859 vùng từ được nhận dạng (Bảng 5). Xử lý hết tập ảnh cho biết đường chạy hoạt động đầy đủ; chất lượng chữ cần được xem qua phép đo và rà soát riêng.

Bảng 5: Kết quả OCR trên 231 ảnh dev nội bộ.

Chỉ số	Kết quả	Cách hiểu
Ảnh có kết quả nhận dạng	231/231	Chương trình xử lý hết tập ảnh dev
Vùng từ được nhận dạng	26.859	Đầu ra để xem chữ và vị trí trên ảnh
CER trên toàn tập (tỷ số)	1,8725	Sai khác ký tự với transcript tham chiếu
WER trên toàn tập (tỷ số)	2,1448	Sai khác token với transcript tham chiếu

4.2 Cách tính và giới hạn của CER/WER

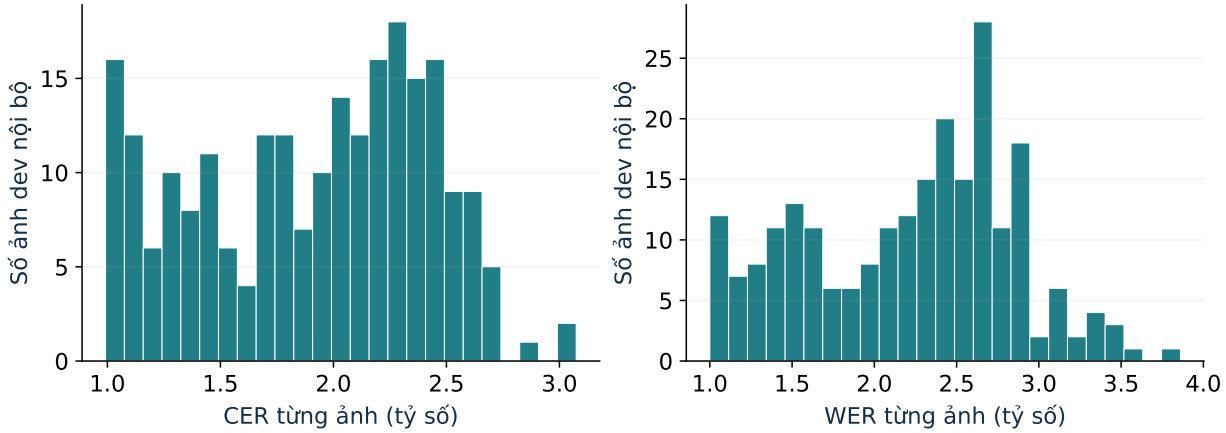
Để tính lỗi, nhóm gán mỗi vùng từ dự đoán vào vùng transcript hợp lệ nhỏ nhất chứa tâm của nó, rồi ghép chữ theo thứ tự từ trên xuống dưới, từ trái sang phải trong từng vùng. Phép đo dùng 8.304 vùng tham chiếu và loại 104 vùng sai hình học. Chữ được chuẩn hóa Unicode, chữ hoa/thường và khoảng trắng; dấu tiếng Việt và dấu câu vẫn được giữ.

CER là tổng số phép chèn, xóa, thay thế ký tự chia cho tổng số ký tự tham chiếu; WER tính tương tự trên các token tách bằng khoảng trắng. Token tiếng Việt ở đây thường là âm tiết. Nhóm cộng số lỗi và độ dài tham chiếu của tất cả vùng rồi mới chia, thay vì lấy trung bình tỷ số từng ảnh. Cả hai tỷ số có thể lớn hơn 1 vì số lỗi, bao gồm lỗi chèn, có thể vượt độ dài tham chiếu.

Giá trị cao cho thấy sai khác lớn theo cách đo hiện tại. Sai khác có thể đến từ nhận dạng, transcript tham chiếu hoặc cách ghép vùng chữ; phân tích hiện tại chưa tách được mức đóng góp của từng nguyên nhân. Vì vậy, không thể dùng riêng CER/WER để kết luận Tesseract đọc sai bao nhiêu phần trăm chữ trên ảnh.

4.3 Quan sát và bài học từ kết quả

Hình 3 cho thấy sai khác phân bố rộng giữa các ảnh. Một tỷ số chung vì thế không thay thế được việc xem các ca cụ thể. Khi rà soát tiếp, cần ưu tiên cả ảnh có sai khác cao lẫn các vùng không ghép được để xác định phép đo đang bỏ qua hoặc phạt những nội dung nào.



Hình 3: Mức sai khác OCR giữa các ảnh dev không đồng đều; biểu đồ dùng cùng cách ghép vùng với chỉ số trong Bảng 5.

Có 1.886 vùng tham chiếu không nhận được vùng từ tương ứng; các vùng này được tính với chuỗi nhận dạng rỗng, tạo lỗi xóa. Ngược lại, 10.488 vùng từ dự đoán không được gán vào tham chiếu hợp lệ chỉ được đếm riêng, chưa đi vào CER/WER. Đây là dấu hiệu cần kiểm tra, chưa tự chứng minh lỗi bỏ sót hoặc nhận thừa của OCR. Nhóm chưa báo cáo độ chính xác phát hiện vùng chữ vì đầu ra theo từ và nhãn theo dòng/nhóm chữ khác đơn vị.

Khoảng 39% số vùng từ dự đoán chưa được ghép, nên tỷ số hiện tại không phản ánh trực tiếp mọi đầu ra của engine. Cần kiểm chứng cả các cặp ghép và phần chưa ghép trước khi so sánh mô hình. Phân tích tuần 1 dừng ở chẩn đoán; chưa có phân loại nguyên nhân do người rà soát gán cho từng ca OCR.

V. Thảo luận

Ba mục tiêu hỗ trợ nhau: EDA và rà soát nhãn chỉ ra rủi ro giám sát sai; chuẩn hóa giữ nguồn và trạng thái lỗi để có thể đối chiếu; OCR tạo đầu ra để khảo sát nhận dạng và phép đo. Kết quả chung là xác định được những điều kiện cần kiểm tra trước khi phát triển mô hình trích xuất thông tin.

Tính tái lập giữ đầu vào và cách chia tập ổn định để đối chiếu các thay đổi sau này. Tuy nhiên, lỗi nhãn được lặp lại nhất quán vẫn là lỗi nhãn; ngăn trùng chính xác cũng chưa giải quyết ảnh cùng giao dịch đã bị cắt hoặc chụp lại. Tính nhất quán, chất lượng annotation và rủi ro gần trùng cần được đánh giá riêng.

Baseline cho phép đo sai khác theo quy tắc rõ ràng, nhưng chưa xác định đóng góp của từng nguyên nhân hoặc chất lượng KIE. Ưu tiên hiện tại là kiểm chứng phép đo và chuẩn bị nhãn đã phân xử để tránh biến sai sót dữ liệu thành kết luận về mô hình.

VI. Kết luận và hướng tiếp theo

Tuần 1 đã hoàn thành khảo sát dữ liệu, quy trình chuẩn bị có thể lặp lại và một mốc OCR trên tập dev. Các giới hạn về nhãn, gần trùng và ghép vùng đã được xác định để định hướng bước phát triển tiếp theo.

Bước tiếp theo được ưu tiên theo thứ tự: phân xử các nhãn và quy ước loại chứng từ cần dùng cho đánh giá; xác định danh tính giao dịch của các cặp nghi gần trùng; kiểm chứng cách ghép OCR với transcript trên các ca đại diện; sau đó xây dựng và đánh giá mô hình trích xuất bốn trường trên tập đã kiểm tra. Các kết quả cần được đo ở mức thông tin trích xuất và đối chiếu trực tiếp trên ảnh trước khi hướng tới ứng dụng cho người dùng.

Tài liệu tham khảo

[1] MC-OCR Challenge. *Mobile captured receipts OCR*.
https://www.rivf2021-mc-ocr.vietnlp.com/

[2] Tesseract OCR. *Tài liệu sử dụng*.
https://tesseract-ocr.github.io/tessdoc/

[3] DocuCheck AI. *Kho mã dự án*.
https://github.com/AIVIETNAM-AIO-Heart208/DocuCheck-AI